



SmartPricing AI: Cotizaciones inteligentes para servicios de Facility Management

Equipo 54

José Emmanuelle Montante Díaz - A01150895
David Emmanuel Villanueva Martínez - A01638389
Juan Martín Valdez Rodríguez - A01796412

Avance 6 – Conclusiones clave

Asesor

Horacio Martínez Alfaro

Proyecto Integrador

Junio 14, 2026

En el presente entregable se exponen las conclusiones obtenidas por el equipo de trabajo durante el desarrollo del proyecto Smart Pricing AI, resultado de las actividades de análisis, diseño, implementación y evaluación de modelos de ML capaces de estimar los costos de proyectos B2B de Facility Management; de igual manera, se documentan las contribuciones y logros más importantes obtenidos durante la ejecución del proyecto

Como parte de visión de continuidad del proyecto en iteraciones futuras, se presentan los pasos a seguir recomendados para su evolución y mejora, incluyendo funcionalidades futuras y tareas necesarias para fortalecer la solución y ampliar su alcance en escenarios reales de negocio.

Finalmente, se incluye un análisis comparativo de distintas alternativas de implementación en la nube, con el propósito de evaluar tanto la factibilidad técnica, como la operativa y económica que permitan la implementación de la solución en distintos entornos.

Análisis del modelo

¿El rendimiento del modelo es lo suficientemente bueno para su implementación en producción?

Sí. Los resultados obtenidos indican que el modelo posee un nivel de desempeño suficiente para apoyar procesos de estimación económica dentro de ACCIONA Facility Services.

Durante el proyecto se evaluaron múltiples algoritmos de Machine Learning y estrategias de ensamble utilizando validación cruzada repetida, logrando superar consistentemente al modelo baseline utilizado como referencia.

Comparación cuantitativa de los modelos de ML

Modelo	MAPE	RMSE	R2
Dummy Baseline	123.04%	0.74	-0.06
Mejor modelo individual	41.49%	0.27	0.85
Modelo final Ensemble	35.22%	0.23	0.89

Esto demuestra que las instancias de datos cuentan con la información suficiente para realizar una predicción, aunque el rendimiento y efectividad de estas predicciones dependerá de la capacidad de generalización de cada modelo.

Si bien se identificaron oportunidades de mejora en segmentos específicos, particularmente en la región CENTRO, el desempeño global alcanzado demuestra que la solución es técnicamente viable para ser implementada inicialmente en un entorno controlado o piloto, evolucionando posteriormente hacia una implementación productiva completa.

El equipo identifica las siguientes condiciones a cumplir que permiten avanzar hacia un entorno de producción:

Condición	Horizonte	Métrica de éxito
Incremento de instancias de datos	6 meses	Mas de 500 cotizaciones históricas
Implementación de control de versiones para modelos de ML	3 meses	100% de experimentos registrados
Ejecución de pruebas piloto	3 meses	Validación de efectividad basada en retroalimentación de usuarios
Implementación de esquema de monitoreo de producción	6 meses	Dashboard operativo
Formalización de proceso de reentrenamiento	6 meses	Procedimiento establecido y documentado

¿Existe margen para mejorar aún más el rendimiento?

Sí. Aunque los resultados obtenidos son satisfactorios, existen oportunidades claras para incrementar la precisión del modelo.

Particularmente, los análisis realizados identificaron que la región CENTRO presenta niveles de error superiores al promedio general. Esto sugiere la necesidad de incrementar el número de observaciones disponibles para esta categoría o incorporar variables adicionales que permitan capturar mejor las características específicas de dichos proyectos.

Asimismo, futuras iteraciones podrían incorporar nuevas variables operativas, financieras y comerciales que contribuyan a mejorar la capacidad predictiva del sistema.

¿Cuáles serían las recomendaciones clave para poder implementar la solución?

El equipo identifica las siguientes recomendaciones para una mejor implementación del proyecto:

Incremento de instancias de datos

El histórico de datos proporcionado por la empresa para el desarrollo de este proyecto fue bastante reducido, con apenas 124 cotizaciones, por motivos de tiempo se decidió trabajar con este dataset reducido, empleando estrategias de validación cruzada para minimizar el impacto de la cantidad de datos.

Para futuras iteraciones de este proyecto, es recomendado, además de aplicar validación cruzada, aumentar el número de muestras/cotizaciones de entrenamiento, de esta manera podemos asegurar una mayor robustez de los modelos implementados, se pudieran generar datos sintéticos con debida supervisión o trabajar directamente con miembros de la empresa para realizar cotizaciones prueba que nos ayuden a generalizar los resultados.

Definición de pipeline end-to-end

La solución desarrollada implementa un pipeline de procesamiento de datos que se alinea con los principios y buenas prácticas de la metodología MLops, cuyo objetivo se basa en la integración y despliegue continuos de modelos de Machine Learning en entornos de producción, de esta manera se permite establecer procesos estandarizados y reproducibles para la gestión del ciclo de vida de estos modelos, permitiendo la escalabilidad, mantenibilidad y trazabilidad de etapas futuras.

Durante el desarrollo del proyecto se logró implementar satisfactoriamente las fases correspondientes a la ingesta, limpieza, transformación y preparación de datos, estableciendo una base sólida para la construcción de nuestros modelos predictivos, esto permite garantizar la calidad y consistencia de la información utilizada, así como la generación de features relevantes para futuros procesos de entrenamiento.

Sin embargo, el alcance actual del pipeline se limita hasta la fase de transformación de datos, por lo que aún existen componentes fundamentales que deben de ser desarrollados para alcanzar una implementación completa que se alinee con un entorno de producción, entre estos componentes se encuentran la partición del conjunto de datos de entrenamiento, validación y prueba de los modelos desarrollados

En consecuencia, la recomendación se basa en la incorporación de estas fases dentro de la arquitectura actual del proyecto, permitiendo evolucionar hacia un ecosistema MLops completo

Control de versiones de modelado

Esta recomendación complementa directamente la anterior, y propone la adopción de herramientas especializadas como MLflow que permiten gestionar el ciclo de vida de los modelos de ML y sus procesos de optimización de parámetros, se enfoca en el diseño, registro y seguimiento de experimentos, métricas y configuraciones usadas en cada iteración

El uso de estas herramientas permite y facilita la comparación objetiva del desempeño entre modelos o variantes-versiones de ellos, logrando identificar rápidamente las configuraciones que generan los mejores resultados, asimismo, el control histórico de los experimentos contribuye a garantizar la reproducibilidad de los resultados y simplificar las actividades de mantenimiento del sistema.

Interfaz gráfica para facilitar la interacción con el sistema

Se considera altamente recomendable la implementación de una interfaz gráfica (GUI) que permita a los usuarios finales interactuar con los modelos de Machine Learning de manera intuitiva y eficiente, esta incorporación contribuiría significativamente a mejorar la experiencia de uso del sistema, facilitando su adopción y haciendo más eficiente el tiempo de capacitación.

En general, el desarrollo de una capa de interacción orientada hacia el usuario representa un punto clave para transformar el sistema en una solución más accesible, escalable y alineada con las necesidades reales de los responsables de la generación de cotizaciones.

Respuestas a preguntas clave planteadas al inicio del proyecto

¿Qué factores tienen mayor impacto en el costo de un servicio?

Los análisis exploratorios, la selección de variables y los modelos desarrollados permitieron identificar que los principales impulsores del costo de un servicio están relacionados con la estructura operativa requerida para su ejecución. Entre los factores más relevantes destacan la cantidad de personal asignado, la complejidad operativa del servicio, la región geográfica donde se presta, el tipo de servicio contratado y la duración del proyecto.

Adicionalmente, variables asociadas a especialidades técnicas, requerimientos de supervisión, turnos de operación y cobertura de servicio mostraron una influencia significativa sobre el costo final de las propuestas. Estos hallazgos confirman que el costo de un servicio no depende de una sola variable, sino de la combinación de factores operativos, comerciales y geográficos.

¿Cómo se pueden identificar patrones en propuestas históricas?

Los patrones en propuestas históricas pueden identificarse mediante técnicas de análisis exploratorio de datos, ingeniería de características y modelos de aprendizaje automático. A través del análisis realizado fue posible detectar relaciones recurrentes entre variables operativas, estructuras de personal, tipos de servicio y niveles de facturación.

Asimismo, los modelos permitieron identificar segmentos de clientes y configuraciones operativas que comparten comportamientos similares, facilitando la detección de tendencias y criterios comunes utilizados históricamente en la construcción de propuestas comerciales. Esto permite transformar conocimiento previamente implícito en reglas y patrones medibles que pueden ser utilizados para apoyar futuras decisiones comerciales.

¿Es posible definir estructuras operativas óptimas a partir de datos previos?

Sí. Los resultados obtenidos demuestran que es posible utilizar información histórica para identificar configuraciones operativas que han generado resultados exitosos en proyectos similares. El análisis de cotizaciones previas permite reconocer patrones asociados a niveles de personal, supervisión, especialidades técnicas y cobertura operativa que se repiten en determinados tipos de servicio.

Aunque la decisión final siempre requiere validación por parte de expertos del negocio, el sistema SmartPricing AI puede servir como una herramienta de apoyo para recomendar estructuras operativas consistentes con experiencias previas, reduciendo tiempos de análisis y promoviendo una mayor estandarización en el diseño de propuestas comerciales.

Validación de objetivos del proyecto

A continuación, retomaremos los objetivos que se plantearon en la definición del proyecto y evaluaremos si los logros alcanzados cumplen con estos mismos,

1. Reducir los tiempos de elaboración de propuestas

Uno de los principales beneficios del desarrollo de este proyecto, es la reducción significativa en tiempos requeridos para la elaboración de cotizaciones de servicios. Mediante la aplicación de técnicas de Análisis de Datos y modelado ML, el sistema es capaz de procesar la información recopilada durante las etapas iniciales de interacción con el cliente y generar una estimación del costo final en cuestión de segundos.

Esta capacidad representa una mejora respecto al proceso tradicional usado previamente, donde la elaboración de una cotización requería la participación de personal especializado para construir una propuesta alineada con los requerimientos específicos de cada cliente, pudiendo tardar horas o hasta 10 días en preparar la propuesta debido a la complejidad inherente de servicios de Facility Management

2. Mejorar la precisión en la estimación de costos

A través de la evaluación de múltiples algoritmos de Machine Learning, técnicas de validación cruzada repetida y estrategias de ensamble, fue posible desarrollar modelos

capaces de generar estimaciones significativamente más precisas que el baseline utilizado como referencia inicial.

La comparación sistemática entre modelos permitió identificar configuraciones con menor error de predicción, incrementando la confiabilidad de las estimaciones generadas. Adicionalmente, los análisis de importancia de variables permitieron comprender mejor los factores que influyen en el costo final de los servicios, fortaleciendo el proceso de estimación.

Por lo anterior, se considera que el objetivo de mejorar la precisión en la estimación de costos fue alcanzado satisfactoriamente.

3. Estandarizar la lógica de diseño de servicios

Durante el desarrollo de este proyecto, se realizó un proceso exhaustivo de exploración y análisis de datos con el fin de comprender profundamente las variables que influyen directamente en la estimación de los costos finales de proyectos de Facility Management gestionados por la empresa ACCIONA, en esta fase se identificaron patrones, relaciones y factores clave dentro del histórico de datos que se tenía disponible, proporcionando una base sólida para la definición de criterios de estimación más consistentes y bien fundamentados.

En consecuencia, se ha fortalecido significativamente la lógica utilizada para la generación de cotizaciones, optimizando el flujo de trabajo desde la etapa de levantamiento de requerimientos con el cliente hasta la elaboración de la cotización final

4. Apoyar la toma de decisiones comerciales con base en datos

El proyecto SmartPricing AI transforma información histórica de cotizaciones en conocimiento accionable para apoyar la toma de decisiones comerciales.

Los modelos desarrollados permiten identificar patrones de comportamiento, variables críticas de costo y configuraciones operativas asociadas a proyectos exitosos, proporcionando evidencia cuantitativa para respaldar decisiones que anteriormente dependían principalmente de experiencia individual.

De esta manera, la solución desarrollada contribuye a reducir la incertidumbre durante la elaboración de propuestas comerciales y promueve una cultura de toma de decisiones basada en datos dentro de ACCIONA Facility Services.

Por lo tanto, se considera que este objetivo también fue alcanzado.

Accionables

Acción	Justificación	Stakeholder responsable
Incrementar el histórico de cotizaciones disponible para entrenamiento	Mejorar la capacidad predictiva y reducir el error en segmentos poco representados	Dirección Comercial ACCIONA
Incorporar nuevas variables operativas y financieras	Enriquecer la información utilizada por los modelos	Dirección Comercial y Finanzas
Completar el pipeline MLOps con etapas de entrenamiento y despliegue	Garantizar escalabilidad y reproducibilidad	Equipo MLOps
Implementar MLflow para trazabilidad de experimentos	Controlar versiones y facilitar auditorías de modelos	Equipo de Desarrollo
Desarrollar interfaz gráfica para usuarios comerciales	Facilitar adopción y uso operativo del sistema	Equipo de Desarrollo
Ejecutar pruebas piloto con usuarios reales	Validar utilidad de negocio y detectar mejoras	Usuarios finales y Dirección Comercial
Monitorear desempeño del modelo en producción	Detectar degradación o deriva de datos	Equipo MLOps
Reentrenar periódicamente el modelo	Mantener precisión conforme evolucionen las condiciones del negocio	Equipo de Ciencia de datos

Horizonte de implementación

Corto plazo (0-6 meses):

- Incrementar histórico de cotizaciones.
- Implementar MLflow.
- Ejecutar pruebas piloto.

Mediano plazo (6-12 meses):

- Completar pipeline MLOps.
- Implementar monitoreo.
- Incorporar nuevas variables.

Largo plazo (12+ meses):

- Desarrollar interfaz gráfica.
- Implementar despliegue Cloud productivo.
- Automatizar reentrenamiento.

Método de implementación

La implementación de SmartPricing AI se considera como un proceso gradual orientado a minimizar riesgos operativos y maximizar la adopción por parte de usuarios finales, y debido a que esto impacta directamente en la generación de cotizaciones comerciales, se busca una estrategia de despliegue progresiva que permita validar el comportamiento del sistema en escenarios reales antes de una liberación productiva completa.

A continuación, se presenta una comparación a alto nivel entre distintos enfoques de implementación en la nube, más adelante se estimará el costo total de propiedad tomando en cuenta otros factores

Factor	AWS	Microsoft Azure	Google Cloud Platform	IBM Watson
Servicio principal ML	SageMaker	Azure Machine Learning	Vertex AI	Watson Studio
Facilidad de uso	Alta	Alta	Muy Alta	Alta
Escalabilidad	Muy alta	Muy alta	Muy alta	Alta
Integración con Python	Excelente	Excelente	Excelente	Buena
Capacidades MLOps	Muy completas	Muy completas	Muy completas	Adecuadas
Curva de aprendizaje	Media	Media	Baja	Media
Compatibilidad con pipelines reproducibles	Excelente	Excelente	Excelente	Buena
Costo estimado mensual (PoC / piloto)	USD \$80 – \$150	USD \$90 – \$160	USD \$60 – \$120	USD \$100 – \$180
Costo estimado mensual (producción inicial)	USD \$200 – \$500	USD \$250 – \$550	USD \$180 – \$450	USD \$300 – \$600
Adecuación para SmartPricing AI	Alta	Alta	Muy Alta	Media

Service Level Agreement (SLO)

Objetivos de nivel de servicio

Para garantizar una operación estable y confiable del sistema en producción, se proponen los siguientes objetivos de nivel de servicio:

Indicador	Objetivo	Justificación
Disponibilidad	99.5 %	Garantizar acceso continuo para el área comercial

Latencia de respuesta	< 2 s	Respuesta inmediata durante elaboración de cotizaciones
Tasa de error	< 1 %	Reducir interrupciones operativas
Throughput	~20 solicitudes/hora	Suficiente para volumen esperado de usuarios

Monitoreo de datos

Monitoreo existente

Para lograr un buen funcionamiento y fácil detección de errores, el sistema implementa su propio mecanismo nativo de registro de eventos (logging) el cual documenta paso a paso la ejecución de las distintas etapas durante el entrenamiento e inferencia, este histórico busca la mitigación de problemas y la reducción significativa de resolución de fallas (MTTR) durante el soporte.

Observabilidad y Monitoreo en la nube

Con el despliegue del sistema en una infraestructura en la nube, se requiere elevar los niveles de monitoreo para permitir auditoria corporativa, análisis de rendimiento y seguridad, por lo que la telemetría actual no es suficiente para el monitoreo de sistema a nivel de negocio (costo total, uso promedio, efectividad, etc)

Por lo tanto, se propone registrar los siguientes metadatos en cada request en producción:

Parámetro	Propósito y Valor
Timestamp	Se registra la fecha y hora precisa de la predicción, permitiendo la correlación y guardando el histórico de eventos
Variables de entrada e indicadores de importancia	Guarda los vectores de características recibidos y el peso de las variables en la predicción, facilitando la detección de sesgos y/o data drift
Resultado de la predicción	Registra la salida generada por el modelo para su posterior validación, a través de métricas de precisión en producción
Tiempo de inferencia	Mide el tiempo exacto que le toma al modelo procesar la solicitud y generar la predicción, punto crítico para el monitoreo de SLA y
Estado de la solicitud	Captura el estado de la transacción a través de códigos HTTP, agilizando la detección de errores en la implementación API

Monitoreo del desempeño predictivo

Ademas del monitoreo operacional descrito anteriormente, se evaluará con una cadencia mensual, la calidad predictiva de las respuestas del modelo mediante las siguientes métricas:

- Mean Absolute Error (MAE)
- Root Mean Squared Error (RMSE)
- Mean Absolute Percentage Error (MAPE)
- Comparación entre predicciones

En caso de detectarse una degradación superior al 15% respecto al desempeño validado durante el desarrollo, se activará un proceso de revisión de datos y reentrenamiento del modelo

Este esquema de monitoreo permite la creación de tableros de control (dashboards) de negocio en tiempo real y asegurando que el sistema sea completamente auditable, escalable y mantenible a largo plazo en el ambiente de producción en la nube.

Gestión de alertas

Con el objetivo de garantizar la disponibilidad y confiabilidad del sistema SmartPricing AI en producción, se propone implementar un sistema de alertas automatizado que permita la detección oportuna de incidentes operativos y degradaciones de rendimiento del modelo, notificando de forma inmediata a los equipos responsables mediante correo electrónico, plataformas de mensajería corporativa como Microsoft Teams o Slack o sistemas de gestión de incidentes.

Clasificación de alertas

Se propone la siguiente clasificación en tres niveles de severidad:

Nivel	Descripción	Tiempo de atención
Critica	Interrupción total del servicio o degradación severa del modelo	> 1 hora
Alta	Impacto significativo en el desempeño y calidad de las predicciones	> 4 horas
Media	Comportamientos anómalos que requieren atención	> 24 horas

Alertas operativas

Supervisan la salud del sistema, infraestructura y el servicio de inferencia, se presentan a continuación:

Evento	Condición	Severidad	Acciones recomendadas
Disponibilidad de servicio	Menor a 99.5%	Critica	Escalamiento inmediato hacia el equipo de MLOps
Predicciones fallidas consecutivas	> 5 eventos	Critica	Seguir procedimiento de recuperación
Latencia P95	> 2 segundos	Alta	Revisar recursos computacionales y carga del sistema
Uso de CPU	> 85% durante 10 minutos	Media	Evaluar escalamiento
Uso de memoria	> 90% durante 10 minutos	Alta	Analizar consumo de recursos

Flujo de respuesta ante incidentes

Al momento de la detección de cualquier alerta, se seguirá el siguiente flujo:

1. Alerta activada, detección automática mediante la plataforma de monitoreo
2. Notificación inmediata al responsable asignado
3. Clasificación del incidente según la severidad
4. Diagnóstico inicial y análisis de causas
5. Aplicación de acciones correctivas
6. Validación de recuperación del servicio
7. Documentación del incidente

Recomendación de acciones de mitigación

Dependiendo del incidente que se presente, se recomienda la ejecución de las siguientes acciones correctivas:

- Reinicio del servicio de inferencia
- Escalamiento dinámico de los recursos de la infraestructura en la nube
- Restauración de una versión previa del modelo a través de MLflow
- Reentrenamiento del modelo utilizando instancias de datos actualizadas
- Revisión y corrección de problemas de calidad de datos en la etapa de ingestión

Total Cost of Ownership

La implementación de SmartPricing AI implica costos asociados a infraestructura cloud, almacenamiento de datos, monitoreo, mantenimiento de modelos y soporte operativo, por lo cual, se estiman los siguientes costos anuales:

Plataforma	PoC anual (USD)	Producción anual (USD)
AWS	\$ 900 – 1,800	\$ 2,400 – 6,000
Azure	\$ 1,080 – 1,920	\$ 3,000 – 6,600
Google Cloud Platform	\$ 720 – 1,440	\$ 2,160 – 5,400
IBM Watson	\$ 1,200 – 2,160	\$ 3,600 – 7,200

Para una etapa piloto se estima un costo mensual entre USD \$60 y USD \$120 utilizando Google Cloud Platform y Vertex AI. En una fase productiva inicial el costo puede incrementarse a un rango aproximado de USD \$180 a USD \$450 mensuales dependiendo del volumen de consultas, almacenamiento histórico y frecuencia de reentrenamiento.

Adicionalmente, deben considerarse costos indirectos asociados a mantenimiento evolutivo, monitoreo, actualización de modelos y capacitación de usuarios. Sin embargo, estos costos son compensados por los beneficios derivados de una reducción en tiempos de elaboración de propuestas, mayor consistencia en las estimaciones y mejor soporte para la toma de decisiones comerciales.

Consideración económica

Los costos mostrados corresponden a estimaciones referenciales para un entorno de Machine Learning de tamaño medio, considerando almacenamiento de datos, entrenamiento periódico de modelos, despliegue de endpoints predictivos y monitoreo básico.

Debido a que SmartPricing AI procesa volúmenes moderados de información y no requiere entrenamiento en tiempo real ni infraestructura de cómputo intensiva, Google Cloud Platform presenta la mejor relación costo-beneficio para una etapa inicial de implementación.

La diferencia de costos entre proveedores no es determinante por sí sola; sin embargo, al combinar capacidades analíticas, facilidad de despliegue mediante Vertex AI, integración con Python y costos operativos competitivos, **Google Cloud se posiciona como la alternativa más adecuada para ACCIONA Facility Services.**

Riesgos de dependencia tecnológica (Vendor Lock-In)

La adopción de servicios administrados en la nube puede generar dependencia tecnológica respecto al proveedor seleccionado, dificultando una futura migración hacia otra plataforma.

Para mitigar este riesgo, se recomienda mantener una arquitectura basada en estándares abiertos, utilizar formatos portables para almacenamiento de modelos

(joblib, pickle, ONNX), documentar adecuadamente los pipelines y minimizar el uso de servicios propietarios cuando existan alternativas equivalentes.

Específicamente, se recomiendan las siguientes medidas preventivas:

- Utilizar contenedores de Docker para encapsular ambientes
- Mantener pipelines desarrollados en Python
- Emplear MLFlow para gestión de modelos
- Documentación de procesos de CI/CD

De esta manera, ACCIONA podrá conservar flexibilidad tecnológica y reducir costos asociados a futuras migraciones.

Residencia de datos

La información utilizada por SmartPricing AI contiene datos comerciales y operativos de ACCIONA Facility Services, por lo que resulta importante definir políticas claras sobre almacenamiento y ubicación geográfica de la información.

Se recomienda utilizar regiones cloud ubicadas en América del Norte o regiones autorizadas por las políticas corporativas de ACCIONA, garantizando cumplimiento regulatorio, disponibilidad y continuidad operativa.

Asimismo, deben establecerse políticas de respaldo, retención y recuperación de información alineadas con los lineamientos internos de gobierno de datos.

Seguridad, Compliance y PII

La solución deberá cumplir con los lineamientos corporativos de seguridad de la información definidos por ACCIONA.

Aunque el proyecto utiliza principalmente información comercial y operativa, se recomienda aplicar controles de acceso basados en roles, cifrado de información en tránsito y en reposo, autenticación multifactor para usuarios administradores y mecanismos de auditoría para el seguimiento de actividades.

En caso de incorporarse información personal identificable (PII) en futuras versiones, será necesario implementar políticas adicionales de protección de datos conforme a la legislación aplicable y a los estándares corporativos de privacidad.

Clasificación de la información

En términos de gobernanza de datos, la información utilizada por el sistema puede clasificarse de la siguiente manera:

Tipo de información	Clasificación
Datos históricos de cotizaciones	Confidencial
Información de clientes de ACCIONA	Confidencial
Costos operativos y financieros	Confidencial
Configuración del sistema e infraestructura	Restringida
Métricas de desempeño del modelo	Interna
Documentación técnica	Interna

Al realizar esta clasificación, se permiten definir controles de acceso y almacenamiento de datos según el nivel de sensibilidad de la información

Controls de acceso basado en roles (RBAC)

Es de vital importancia definir perfiles de acceso, se consideran:

Rol	Responsabilidad
Usuario Comercial	Generar consultas (predicciones) y visualizar resultados
Supervisor comercial	Validar estimaciones y monitoreas uso de los usuarios
Científico de datos	Gestión y reentrenamiento de modelos
Administrados MLOps	Gestion de infraestructura y despliegues
Administrados de Seguridad	Auditoria y control de accesos

Encapsulación de ambientes

Es altamente recomendable la separación de ambientes para desarrollo, pruebas y producción, esto ayuda a reducir de manera significativa el riesgo de cambios accidentales en entornos de producción.

Cumplimiento normativo

El equipo recomienda tomar en cuenta principios derivados de normas internacionales, por ejemplo:

- ISO 27001 – Gestión de seguridad de la información
- ISO 27017 – Controles de seguridad en servicios en la nube
- ISO 27701 – Privacidad de la información

La adopción de estas prácticas facilitará futuras auditorias y procesos de certificación en caso de ser necesario.

Plan de transferencia al patrocinador

Con el objetivo de asegurar la continuidad operativa de la solución propuesta después de la finalización del proyecto, se propone realizar una transferencia formal de conocimiento hacia el patrocinador ACCIONA, incluyendo los siguientes entregables:

- Repositorio de código fuente: Dentro de él, se encuentra todo el código desarrollado para lograr los objetivos del proyecto, fundamental para handoff
- Modelo entrenado y serializado: Se entregará el mejor modelo de ML de acuerdo con los experimentos desarrollados, en un formato joblib para estandarizar y facilitar el uso futuro
- Documentación técnica: Documentación clara y concisa acerca del sistema, explicando su funcionamiento, su estructura, implementación, etc.
- Arquitectura del sistema: Esquemas generales de la implementación del sistema, clave para entender relaciones entre archivos y entradas/salidas del sistema
- Configuración de infraestructura: Requerimientos necesarios para la ejecución de la solución dentro del ambiente establecido al inicio del proyecto
- Recomendaciones finales: Áreas de oportunidad y de mejora identificadas a lo largo del desarrollo del proyecto, contribuye no solo a la mitigación de riesgos actuales, sino que robustece la calidad de los entregables finales y sienta las bases para futuras implementaciones.

Responsabilidad Operativa

Posterior a la entrega del sistema hacia el sponsor, la ejecución, administración y mantenimiento recaerá sobre las áreas responsables designadas por ACCIONA Facility Services, definiendo como responsables:

Actividad	Responsable
Infraestructura Cloud	Area de Tecnología / Desarrollo
Monitoreo Operacional	Equipo MLOps
Mantenimiento y reentrenamiento de modelos de ML	Equipo de Ciencia de Datos / MLOps
Gestión de usuarios	Area de Tecnología / Desarrollo
Validación de resultados	Dirección comercial / Usuarios finales capacitados
Costos	Area de Tecnología / Dirección ejecutiva

Mecanismos de alineación estratégica

Gestión de stakeholders y alineación con el patrocinador

Se plantean y comunican los principales logros obtenidos a lo largo del desarrollo de la solución, haciendo énfasis en puntos de mejora, riesgos identificados y recomendaciones finales.

Transferencia de conocimiento y sesiones de capacitación

Mediante sesiones de transferencia y capacitación orientadas a usuarios clave y administradores del sistema, se mitigan las asimetrías de información, reduciendo los tiempos de adopción y la curva de aprendizaje.

Delegación de funciones y trabajo colaborativo

En secciones anteriores se identificaron recomendaciones accionables post-handoff donde se incluyen responsabilidades hacia distintas áreas de la empresa, de esta manera, el equipo receptor conoce claramente las funciones, dependencias y tareas a implementar, promoviendo así, el trabajo en equipo autosuficiente.

A través del esquema anterior, la entrega final no se limita solo a un traspaso de entregables, al integrar las lecciones aprendidas, recomendaciones finales y la habilitación técnica del equipo operativo, se transforma el cierre del proyecto en una guía accionable para el éxito del negocio

Decomissioning

Aunque la solución SmartPricing AI está diseñada para ser implementada en etapas, es importante definir una estrategia formal para su retiro en caso de que el sponsor decida no continuar con la implementación, a esta estrategia se le conoce como decomissioning y busca garantizar que la desactivación del sistema se realice de forma segura, controlada y trazable, minimizando riesgos operativos, financieros y de seguridad.

El plan de Decomissioning se basa en las siguientes fases:

Fase 1: Evaluación

Antes de iniciar con cualquier procedimiento, se deberá de realizar una evaluación la cual determine el impacto asociado a la discontinuación del sistema, de esta manera se exponen posibles riesgos, beneficios y consecuencias de la decisión, esta evaluación deberá incluir:

- Afectaciones en procesos de negocio
- Cantidad de usuarios afectados que usan activamente la plataforma
- Dependencias tecnológicas
- Contratos existentes de Cloud services

Fase 2: Preservación de activos

Asimismo, se deberá realizar un respaldo de activos críticos involucrados dentro del proyecto, esta información se almacenará en repositorios/sistemas autorizados por la empresa ACCIONA para asegurar trazabilidad futura.

Algunos activos de importancia identificados son:

- Código fuente del proyecto
- Configuración de infraestructura
- Histórico de datasets utilizados para entrenamiento
- Métricas de desempeño
- Documentación funcional

Fase 3: Notificación y transición operativa

Es de vital importancia comunicar a los usuarios y áreas involucradas con anticipación sobre la decisión de retiro del sistema y establecer una fecha de retiro, de esta forma se minimiza el impacto de desactivación que se pudiera presentar

Fase 4: Desactivación de infraestructura

En esta fase, comienzan los procesos de desactivación controlada de toda la infraestructura, esto incluye:

- Deshabilitación de endpoints API de inferencia
- Detención de procesos automatizados (Generación de reportes, dashboards, etc.)
- Revocación de credenciales de usuario
- Término y apagado de recursos cloud utilizados en la implementación

Fase 5: Gestión y eliminación de datos

Una vez realizado el respaldo de información relevante, se procede a la eliminación de datos mediante mecanismos de borrado seguro que impidan cualquier recuperación de datos

Fase 6: Auditoría final

Durante esta fase final, se reunirán los stakeholders para realizar una revisión formal y se comprobará que todos los componentes del proyecto se hayan retirado correctamente siguiendo los pasos descritos anteriormente.

Conclusión general del proyecto

SmartPricing AI demostró que es posible utilizar técnicas de análisis de datos y Machine Learning para apoyar el proceso de estimación económica de servicios de Facility Management.

Además de los beneficios técnicos obtenidos, la solución desarrollada tiene el potencial de generar valor económico para ACCIONA mediante la reducción de tiempos de preparación de propuestas, una mayor estandarización de criterios comerciales y una disminución del riesgo asociado a estimaciones manuales.

A lo largo del proyecto se desarrolló un proceso integral que incluyó exploración de datos, ingeniería de características, selección de variables, evaluación de modelos, optimización de hiperparámetros, construcción de ensambles y análisis de interpretabilidad.

Los resultados obtenidos permitieron responder satisfactoriamente las preguntas de investigación planteadas al inicio del proyecto y alcanzar los objetivos definidos durante la Fase 0.

Asimismo, se identificaron oportunidades claras para continuar evolucionando la solución mediante la incorporación de nuevas fuentes de información, automatización completa del pipeline MLOps, monitoreo continuo y despliegue en entornos productivos.

Desde una perspectiva cuantitativa, el proyecto permitió evaluar múltiples algoritmos de Machine Learning, optimizar hiperparámetros mediante validación cruzada repetida y construir modelos de ensamble capaces de superar consistentemente el desempeño del modelo baseline. Estos resultados demuestran que la información histórica de cotizaciones puede ser utilizada para generar estimaciones más robustas y consistentes que los métodos tradicionales basados únicamente en experiencia operativa.

En conclusión, SmartPricing AI representa una solución técnicamente viable y estratégicamente valiosa para apoyar la generación de propuestas comerciales dentro de ACCIONA Facility Services.

Como línea futura de trabajo, se recomienda implementar un proceso formal de monitoreo de desempeño y reentrenamiento periódico que permita mantener actualizado el modelo conforme evolucionen las condiciones operativas y comerciales del negocio.

Impacto estratégico para ACCIONA

La implementación futura de SmartPricing AI no debe visualizarse únicamente como un proyecto tecnológico, sino como una iniciativa de transformación digital para el proceso comercial de ACCIONA Facility Services. La capacidad de estimar costos de manera más rápida, consistente y basada en datos puede convertirse en una ventaja competitiva relevante para responder con mayor velocidad a licitaciones, reducir variabilidad en propuestas y fortalecer la toma de decisiones comerciales en mercados altamente competitivos.

Bibliografía

- Google Cloud. (2026). Vertex AI Documentation. Recuperado de: <https://cloud.google.com/vertex-ai/docs>

- IBM. (2026). IBM Watson Studio Documentation. Recuperado de: <https://www.ibm.com/docs/en/watson-studio>
- Microsoft. (2026). Azure Machine Learning Documentation. Recuperado de: <https://learn.microsoft.com/en-us/azure/machine-learning/>
- Amazon Web Services. (2026). Amazon SageMaker Documentation. Recuperado de: <https://docs.aws.amazon.com/sagemaker/>
- Scikit-learn Developers. (2026). Scikit-learn User Guide. Recuperado de: https://scikit-learn.org/stable/user_guide.html
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., ... Duchesnay, E. (2011). Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, 12, 2825–2830.
- Molnar, C. (2022). Interpretable Machine Learning (2nd Edition). Recuperado de: <https://christophm.github.io/interpretable-ml-book/>
- Geron, A. (2022). Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow (3rd ed.). O'Reilly Media.