



**SmartPricing AI: Cotizaciones inteligentes para servicios de
Facility Management Acciona**

Equipo 54

José Emmanuelle Montante Díaz - A01150895
David Emmanuel Villanueva Martínez - A01638389
Juan Martín Valdez Rodríguez - A01796412

Avance 7 – Resumen Ejecutivo

Asesor

Horacio Martínez Alfaro

Proyecto Integrador

Junio 21, 2026

Resumen Ejecutivo

ACCIONA Facility Services enfrenta el reto de elaborar propuestas técnico-económicas para servicios de Facility Management en un entorno cada vez más competitivo, donde la velocidad de respuesta, la precisión de las estimaciones y la capacidad de atender múltiples oportunidades simultáneamente son factores clave para la adjudicación de contratos.

Con el objetivo de optimizar este proceso, se desarrolló SmartPricing AI, una solución basada en Machine Learning capaz de estimar costos de servicios utilizando información histórica de cotizaciones y variables operativas relevantes.

A partir del análisis de 119 estudios económicos históricos, se evaluaron múltiples algoritmos predictivos y modelos de ensamble. El modelo seleccionado, Voting Weighted, alcanzó un MAPE de 35.22% y un R^2 de 0.89, superando al mejor modelo individual y reduciendo el error en 68.8% respecto al modelo base.

Los resultados demuestran que la inteligencia artificial puede apoyar de forma efectiva la estimación preliminar de costos, proporcionando una herramienta objetiva para la toma de decisiones comerciales. Su implementación permitiría reducir significativamente los tiempos de elaboración de propuestas, estandarizar criterios de costeo entre regiones y líneas de servicio, disminuir la dependencia del conocimiento individual y aumentar la capacidad de atención de oportunidades comerciales.

Considerando que ACCIONA Facility Services tiene como objetivo generar aproximadamente 77 ofertas durante 2026, SmartPricing AI representa una oportunidad para fortalecer la competitividad comercial de la organización mediante procesos más ágiles, consistentes y basados en datos.

Se recomienda avanzar hacia una fase piloto controlada enfocada en fortalecer el volumen de información histórica, implementar mecanismos de gobernanza y monitoreo del modelo, y desarrollar una interfaz de usuario que facilite su adopción por parte de los equipos comerciales y operativos.

Descripción de la problemática

El patrocinador ACCIONA Facility Services opera en un entorno altamente competitivo donde la velocidad de respuesta, precisión en cuanto a estimación de costos, contacto con clientes y la capacidad de construir cotizaciones viables son factores clave para la adjudicación de contratos.

Actualmente, el proceso de diseño de propuestas y cotización de servicios dependen en gran medida de análisis manuales realizados por especialistas comerciales y operativos que hacen uso de herramientas como hojas de cálculo y se basan en la experiencia acumulada, este enfoque permite flexibilidad para adaptarse a cada cliente y cada servicio, sin embargo, también introduce desafíos y riesgos asociados a la consistencia, escalabilidad y eficiencia del proceso.

La dependencia de la experiencia individual puede llegar a influir en la generación de variaciones en los criterios utilizados para la estimación de recursos, dimensionamiento de operaciones y cálculo de costos, lo que puede traducirse en diferencias entre propuestas similares, incrementando el riesgo de subcosteo o sobrecosto que reduce la competitividad de las propuestas frente a otros participantes.

Adicionalmente, la elaboración manual de propuestas requiere una inversión considerable de tiempo y recursos especializados, limitando la capacidad de respuesta de la empresa ante procesos de licitación con plazos reducidos y dificultando la atención simultánea de múltiples oportunidades de negocio.

Ante este escenario, ACCIONA enfrenta una necesidad de evolucionar hacia un nuevo enfoque basado en datos que permita transformar la información histórica de cotizaciones en conocimiento accionable, una clara oportunidad para la implementación de modelos predictivos que mejoren la precisión de las estimaciones reduzca los tiempos de elaboración de propuestas, así como su consistencia con el objetivo de fortalecer la competitividad comercial del patrocinador.

Dicho lo anterior, nuestra solución SmartPricing AI se basa en algoritmos de Machine Learning y tiene como objetivo apoyar el proceso de generación de cotizaciones, mediante la estimación de costos fundamentados en datos históricos y variables operativas relevantes, contribuyendo a una toma de decisiones objetiva y eficientando el tiempo promedio de entrega de propuestas.

Hallazgos más importantes identificados

El análisis exploratorio de datos (EDA) se realizó sobre un histórico de 119 estudios económicos correspondientes a servicios de Facility Management desarrollados por ACCIONA Facility Services. El objetivo fue identificar patrones relevantes, validar la calidad de la información disponible y comprender los principales factores que influyen en el costo de los servicios.

Los hallazgos obtenidos permitieron definir la estrategia de modelado y seleccionar las variables más relevantes para la construcción de SmartPricing AI.

Variables más relevantes

El análisis de correlación, selección de características e importancia de variables permitió identificar que los principales factores asociados al costo de los servicios son aquellos relacionados con la estructura operativa y los costos laborales.

Entre las variables con mayor impacto sobre la facturación anual destacan:

- Número total de empleados asignados al servicio.
- Costos de nómina operativa.
- Costos de seguridad social y prestaciones.
- Costos administrativos.
- Tipo de servicio contratado.
- Región geográfica del proyecto.
- Duración contractual.
- Complejidad operativa del servicio.

Estos resultados confirman que, dentro de los servicios de Facility Management, el componente laboral constituye el principal impulsor del costo total de los contratos, siendo consistente con la realidad operativa del negocio.

Asimismo, se identificó que variables relacionadas con la ubicación geográfica y el tipo de servicio aportan información complementaria importante para explicar diferencias entre proyectos aparentemente similares.

Hallazgos clave del análisis exploratorio

- **Alta variabilidad entre proyectos**

Se observó una dispersión significativa en la variable objetivo (facturación anual), existiendo diferencias superiores a 500 veces entre los contratos de menor y mayor valor económico.

Esta variabilidad confirma la necesidad de utilizar modelos avanzados capaces de capturar relaciones complejas y no lineales entre las variables de entrada y los costos finales.

- **Concentración de datos en ciertos segmentos**

El histórico presenta una mayor concentración de observaciones en determinadas regiones y tipos de servicio, mientras que otros segmentos cuentan con una representación limitada.

Este hallazgo explica parcialmente las diferencias de desempeño observadas posteriormente entre regiones y categorías de servicio, así como la necesidad de incrementar el volumen de datos históricos para futuras versiones del modelo.

- **Presencia de relaciones no lineales**

El análisis bivariado permitió identificar que múltiples variables presentan comportamientos no lineales respecto al costo total del servicio.

Por esta razón se decidió complementar los modelos lineales tradicionales con algoritmos más avanzados como Support Vector Regression (SVR), Random Forest, XGBoost y modelos de ensamble.

- **Calidad adecuada de los datos**

Tras los procesos de limpieza, transformación y validación, se obtuvo un conjunto de datos consistente y apto para el desarrollo de modelos predictivos.

Aunque el volumen de información es limitado, la calidad de los registros permitió construir modelos con niveles de precisión adecuados para una implementación piloto.

- **Oportunidad para estandarizar criterios de costeo**

El análisis permitió identificar diferencias en la composición de costos entre distintos tipos de servicio y regiones.

Este hallazgo refuerza la necesidad de contar con herramientas basadas en datos que permitan estandarizar criterios de estimación y reducir la dependencia del conocimiento individual de cada especialista.

Comparación entre modelos generados

Los hallazgos obtenidos durante el análisis exploratorio permitieron identificar que el comportamiento de los costos depende de múltiples variables operativas y financieras, muchas de ellas con relaciones no lineales. Con base en estos resultados se decidió evaluar diferentes algoritmos de Machine Learning y comparar su desempeño mediante métricas objetivas, con el propósito de seleccionar la alternativa con mayor capacidad predictiva para apoyar el proceso de generación de cotizaciones.

Para evaluar objetivamente el desempeño de los modelos desarrollados se utilizaron tres métricas complementarias:

Se definen las siguientes métricas que servirán como nuestros indicadores de desempeño:

- **MAPE:** (Mean Absolute Percentage Error): mide el porcentaje promedio de error entre el valor real y el valor predicho. Es la métrica principal del proyecto debido

a que permite interpretar de forma intuitiva la precisión de las estimaciones de costos.

- RMSE: RMSE (Root Mean Squared Error): mide la magnitud promedio del error de predicción penalizando con mayor peso los errores grandes. Permite evaluar la precisión absoluta del modelo.
- R² (Coeficiente de Determinación): indica qué proporción de la variabilidad de la facturación anual es explicada por el modelo. Valores cercanos a 1 representan una mejor capacidad explicativa.

Comparación entre modelos generados

Proceso de experimentación

Para llevar un control sobre la generación de modelos y que esta sea lo más efectiva posible, se siguió la siguiente metodología:

1. Desarrollo de modelos base
2. Tuning sobre los modelos base
3. Desarrollo de nuevos modelos basados en ensambles
4. Comparación de métricas entre modelos
5. Elección del modelo final

A continuación, se presenta una comparativa entre los modelos desarrollados, de manera secuencial

Modelos iniciales desarrollados

Modelo	MAPE	RMSE	R2
Dummy	123.04 %	0.74	-0.06
SVR	41.49 %	0.27	0.85
Ridge	52.66 %	0.33	0.78
KNN	53.41 %	0.28	0.85
ElasticNet	53.66 %	0.26	0.86
Lasso	53.68 %	0.26	0.86
Gradient Boosting	54.78 %	0.27	0.85
Random Forest	56.32 %	0.25	0.86
XGBoost	58.56 %	0.27	0.85

El modelo basado en Maquina de Vectores de Soporte fue el que presentó el mejor rendimiento después del tuning de hiperparámetros, por lo que se tomará como principal comparación contra modelos de ensamble.

Modelos de ensamble

Modelo	MAPE	RMSE	R2
Voting_weighted	35.22 %	0.23	0.89

Voting_simple	35.79 %	0.23	0.89
Stacking	39.22 %	0.22	0.89
ExtraTrees_tuned	59.27 %	0.23	0.88
Bagging_tuned	73.12 %	0.26	0.86

Elección del modelo final

El modelo Voting_weighted fue seleccionado como modelo final del proyecto SmartPricing AI por presentar el menor MAPE (35.22%) entre los seis modelos comparados, superando al mejor modelo individual del Avance 4 (SVR, MAPE=41.49%) y representando una mejora de 68.8% sobre el baseline trivial (Dummy, MAPE=112.93%).

Su gap de sobreajuste de 0.07 es el más bajo entre los ensambles evaluados, lo que indica buena capacidad de generalización sobre datos no vistos. Voting_weighted combina cinco familias algorítmicas distintas (Ridge, KNN, SVR, RandomForest y XGBoost) con pesos optimizados, lo que le permite capturar tanto relaciones lineales como patrones no lineales presentes en las cotizaciones de Facility Management, superando a Stacking (MAPE=39.22%) y a los ensambles homogéneos ExtraTrees_tuned (59.27%) y Bagging_tuned (73.12%). Cabe señalar que la prueba estadística (bootstrap) no permite afirmar con 95% de confianza que la mejora frente al mejor modelo individual sea estadísticamente significativa, por lo que se recomienda su adopción como piloto controlado y no como despliegue productivo definitivo hasta validarse con mayor volumen de datos.

Recomendaciones clave para la implementación de la solución

Durante el proceso de desarrollo del proyecto se identificaron áreas de oportunidad para una siguiente iteración, nuevas formas de implementación, mejoras en base al uso, flujos de trabajo, las cuales pueden ser fundamentales en un futuro para una implementación robusta enfocada a ambientes de producción, se identifican:

Incremento de instancias de datos

El histórico de datos proporcionado por la empresa para el desarrollo de este proyecto fue bastante reducido, con apenas 124 cotizaciones, por motivos de tiempo se decidió trabajar con este dataset reducido, empleando estrategias de validación cruzada para minimizar el impacto de la cantidad de datos.

Para futuras iteraciones de este proyecto, es recomendado, además de aplicar validación cruzada, aumentar el número de muestras/cotizaciones de entrenamiento, de esta manera podemos asegurar una mayor robustez de los modelos implementados, se pudieran generar datos sintéticos con debida supervisión o trabajar directamente con miembros de la empresa para realizar cotizaciones prueba que nos ayuden a generalizar los resultados.

Definición de pipeline end-to-end

La solución desarrollada implementa un pipeline de procesamiento de datos que se alinea con los principios y buenas prácticas de la metodología MLOps, cuyo objetivo se basa en la integración y despliegue continuos de modelos de Machine Learning en entornos de producción, de esta manera se permite establecer procesos estandarizados y reproducibles para la gestión del ciclo de vida de estos modelos, permitiendo la escalabilidad, mantenibilidad y trazabilidad de etapas futuras.

Durante el desarrollo del proyecto se logró implementar satisfactoriamente las fases correspondientes a la ingesta, limpieza, transformación y preparación de datos, estableciendo una base sólida para la construcción de nuestros modelos predictivos, esto permite garantizar la calidad y consistencia de la información utilizada, así como la generación de features relevantes para futuros procesos de entrenamiento.

Sin embargo, el alcance actual del pipeline se limita hasta la fase de transformación de datos, por lo que aún existen componentes fundamentales que deben de ser desarrollados para alcanzar una implementación completa que se alinee con un entorno de producción, entre estos componentes se encuentran la partición del conjunto de datos de entrenamiento, validación y prueba de los modelos desarrollados

En consecuencia, la recomendación se basa en la incorporación de estas fases dentro de la arquitectura actual del proyecto, permitiendo evolucionar hacia un ecosistema MLOps completo

Control de versiones de modelado

Esta recomendación complementa directamente la anterior, y propone la adopción de herramientas especializadas como MLflow que permiten gestionar el ciclo de vida de los modelos de ML y sus procesos de optimización de parámetros, se enfoca en el diseño, registro y seguimiento de experimentos, métricas y configuraciones usadas en cada iteración

El uso de estas herramientas permite y facilita la comparación objetiva del desempeño entre modelos o variantes-versiones de ellos, logrando identificar rápidamente las configuraciones que generan los mejores resultados, asimismo, el control histórico de los experimentos contribuye a garantizar la reproducibilidad de los resultados y simplificar las actividades de mantenimiento del sistema.

Interfaz gráfica para facilitar la interacción con el sistema

Se considera altamente recomendable la implementación de una interfaz gráfica (GUI) que permita a los usuarios finales interactuar con los modelos de Machine Learning de manera intuitiva y eficiente, esta incorporación contribuiría significativamente a mejorar la experiencia de uso del sistema, facilitando su adopción y haciendo más eficiente el tiempo de capacitación.

En general, el desarrollo de una capa de interacción orientada hacia el usuario representa un punto clave para transformar el sistema en una solución más accesible, escalable y alineada con las necesidades reales de los responsables de la generación de cotizaciones.

Definición de responsabilidades

Recomendación	Justificación	Responsable	Métrica de validación
Incrementar histórico de cotizaciones para entrenamiento	Mejorar capacidad de generalización del modelo y reducir sesgos por segmentos poco representados	Dirección comercial	~500 cotizaciones disponibles
Complementar pipeline end-to-end	Garantizar reproducibilidad y despliegue productivo	Equipo MLOps	100% reproducibilidad en cualquier sistema
Control de versiones de los modelos de ML	Asegurar trazabilidad de experimentos y auditoría	Equipo Ciencia de Datos	Histórico de versiones e iteraciones de los modelos creados
Desarrollo de interfaz grafica	Facilitar adopción por usuarios finales	Equipo de Desarrollo de Software	Implementación de interfaz gráfica para interacción con los modelos de ML creados

Análisis costo – beneficio

Para estimar la viabilidad del proyecto es muy importante considerar el apartado económico, es decir, que tan costoso fue o seguirá siendo su implementación, por lo que en esta sección se describen los costos asociados al desarrollo, despliegue y operación de la solución propuesta, es relevante resaltar que las cifras presentadas corresponden a estimaciones de referencia para una implementación inicial.

Costos divididos por fase de desarrollo

Basándonos en la metodología CRISP-ML implementada:

Fase	Actividades	Costo estimado (USD)
Comprensión del negocio	Definición de la problemática, levantamiento de requerimientos y objetivos	1,200

Entendimiento de los datos	Recolección, validación, transformación y análisis exploratorio del histórico de cotizaciones	1,800
Preparación de datos	Limpieza, transformación e ingeniería de características	2,000
Modelo ML	Entrenamiento, validación y optimización de hiperparámetros	2,500
Evaluación	Comparación de resultados y validación de métricas	1,000
Despliegue inicial	Infraestructura cloud, configuración MLOps y publicación del servicio	2,500

Costo total estimado de implementación inicial: USD 11,000

Estimación de costos operativos anuales

Dada la estimación de costos iniciales, se deberá definir el costo enfocado en la operación del sistema en producción.

A continuación, se desglosan los costos operativos estimados:

Concepto	Costo estimado anual (USD)
Infraestructura Cloud	\$ 1,200
Almacenamiento	\$ 300
Monitoreo	\$ 500
Reentrenamiento semestral	\$ 1,500
MLflow y control de versiones	\$ 1,000
Soporte técnico	\$ 2,500

Costo operativo anual estimado: USD 7,000

Beneficios operativos

Actualmente, el proceso de elaboración de propuestas en ACCIONA Facility Services depende en gran medida del conocimiento técnico y comercial de especialistas responsables del análisis histórico, dimensionamiento operativo, construcción de costos, generación de escenarios económicos y elaboración de propuestas para clientes.

La implementación de SmartPricing AI permite automatizar parcialmente las actividades de estimación preliminar de costos, reduciendo tareas repetitivas y proporcionando información de apoyo para la toma de decisiones comerciales.

Aunque la solución no sustituye la validación técnica y comercial realizada por especialistas, sí permite acelerar significativamente las etapas iniciales de análisis y construcción económica de las propuestas, mejorando la productividad general del área de ofertas.

Beneficios operativos identificados

Beneficio	Impacto esperado
Reducción del tiempo dedicado a estimación preliminar y análisis histórico	≈30%
Incremento de productividad del área de ofertas	≈30%
Capacidad operativa equivalente generada	≈69,360 EUR/año
Beneficio económico directo estimado	≈11,550 EUR/año
Estandarización de criterios de costeo	Alta
Reducción de retrabajos y ajustes manuales	Media-Alta
Menor dependencia del conocimiento individual	Alta
Mayor velocidad de respuesta ante licitaciones	Alta
Incremento de capacidad para atender oportunidades comerciales	Alta
Mayor consistencia y trazabilidad de las estimaciones	Alta
Facilita la capacitación de nuevos integrantes	Media-Alta
Base tecnológica para futuras iniciativas de IA y analítica predictiva	Alta

Impacto para el negocio

Más allá del ahorro operativo directo, el principal valor de SmartPricing AI consiste en incrementar la capacidad comercial de ACCIONA Facility Services. La solución permite responder con mayor rapidez a procesos de licitación, estandarizar criterios de costeo, reducir la dependencia del conocimiento individual y aumentar la capacidad de atención de oportunidades comerciales sin requerir incrementos proporcionales en la estructura organizacional.

En un entorno donde la velocidad de respuesta y la precisión de las estimaciones influyen directamente en la adjudicación de contratos, SmartPricing AI representa una herramienta estratégica para fortalecer la competitividad y escalabilidad del negocio.

Beneficios económicos

Para estimar el beneficio económico potencial de SmartPricing AI se consideraron los siguientes supuestos:

- 77 ofertas comerciales objetivo para 2026, de acuerdo con los indicadores del CRM de ACCIONA Facility Services.

- 20 horas promedio de trabajo especializado por oportunidad comercial, considerando elaboración de propuestas, ajustes solicitados por clientes, revisiones internas, generación de escenarios alternativos y negociación comercial.
- Costo promedio de trabajo especializado de 25 EUR por hora.
- Reducción estimada del 30% en actividades relacionadas con análisis histórico, estimación preliminar de costos y generación de escenarios económicos.

Situación actual

- 77 oportunidades × 20 horas × 25 EUR = **38,500 EUR anuales**

Situación con SmartPricing AI

- 77 oportunidades × 14 horas × 25 EUR = **26,950 EUR anuales**

Beneficio económico directo estimado

- 38,500 EUR – 26,950 EUR = **11,550 EUR anuales**

Resumen ejecutivo de beneficios económicos

Concepto	Impacto estimado
Ofertas objetivo 2026	77
Horas promedio por oferta	20
Beneficio económico directo	11,550 EUR/año
Costo anual estimado área de ofertas	231,200 EUR/año
Mejora de productividad asumida	30%
Capacidad operativa equivalente generada	69,360 EUR/año

Riesgos identificados

Categoría	Riesgo	Severidad	Probabilidad
Datos	Histórico reducido	Alta	Alta
Datos	Sesgo región Centro	Alta	Media
Ataques	Manipulación de inputs	Media	Media
Ataques	Exposición de información sensible	Alta	Baja
Confianza	Model Drift	Media	Alta
Cumplimiento	Gobernanza	Alta	Media

Limitación en histórico de datos

El modelo se entrenó con apenas 119 estudios económicos, un volumen reducido para un problema de regresión con alta heterogeneidad entre proyectos (la facturación anual varía más de 500 veces entre el caso más pequeño y el más grande). Esto limita la capacidad del modelo para generalizar a combinaciones de variables poco representadas en el histórico, por ejemplo, tipos de servicio con muy pocas observaciones como FACILITY MANAGEMENT (2 casos) o LOGÍSTICA, y aumenta el riesgo de que el desempeño observado en el holdout (MAPE=35.22%) no se replique de forma estable conforme se incorporen nuevos clientes o segmentos de negocio.

Aumento en porcentaje de error en categoría CENTRO

El análisis de error por segmento reveló que la región CENTRO presenta un MAPE de 120.26%, muy por encima de la media global del holdout (47.6%), y que el tipo de servicio LIMPIEZA presenta un MAPE de 76.45% frente al mismo promedio. En contraste, segmentos como SERVICIOS ADMINISTRATIVOS (5.07%), MANTENIMIENTO (15.36%) y la región SUR (12.09%) muestran alta precisión. Esto significa que cotizaciones generadas para clientes de la región CENTRO o del tipo de servicio LIMPIEZA deben tratarse con mayor cautela y revisión manual, ya que el modelo es menos confiable en estos segmentos, probablemente por su menor representatividad en el histórico de entrenamiento, y representan la principal área de riesgo a monitorear conforme se incorporen nuevas cotizaciones.

Tabla de riesgos

Riesgo	Severidad	Mitigación propuesta
Histórico de datos reducido (119 cotizaciones)	Alta	Ampliar el histórico (~500 cotizaciones) y reentrenar el modelo periódicamente con validación cruzada
Error elevado en región CENTRO (MAPE=120.26%) y servicio LIMPIEZA (MAPE=76.45%)	Alta	Marcar como “baja confianza” las cotizaciones de estos segmentos y exigir revisión manual obligatoria por un especialista
Mejora no significativa estadísticamente del ensamble final frente al mejor modelo individual (SVR)	Media	Desplegar primero como piloto controlado y revalidar la diferencia frente a SVR con mayor volumen de datos antes de un despliegue masivo

Asimismo, los riesgos no solo se limitan al rendimiento del modelo o las instancias de datos, a continuación, se describen riesgos existentes implícitos en el desarrollo e implementación del proyecto, divididos por tipo de riesgo

Riesgos relacionados con la seguridad

Riesgos asociados al manejo de información sensible de cotizaciones, costos y datos de clientes de ACCIONA:

Riesgo	Severidad	Mitigación propuesta
Exposición de información comercial sensible (costos, márgenes, clientes) si el modelo o sus datos de entrenamiento se almacenan sin control de acceso	Alta	Restringir acceso al dataset y al modelo mediante control de permisos por rol; evitar el uso de servicios en la nube públicos sin cifrado
Manipulación de inputs por parte de un usuario para obtener una cotización artificialmente baja	Media	La cotización del modelo es siempre una referencia que debe ser validada y firmada por un analista comercial antes de enviarse al cliente
Pérdida o corrupción del artefacto del modelo (joblib) sin respaldo ni control de versiones	Baja	Adoptar MLflow (ya recomendado en la sección anterior) para versionado y respaldo automático de cada modelo entrenado

Riesgos relacionados con pruebas y confianza

Riesgos relacionados con la fiabilidad del modelo y la confianza que los usuarios de negocio depositan en sus resultados:

Riesgo	Severidad	Mitigación propuesta
La mejora de Voting_weighted frente al mejor modelo individual (SVR) no es estadísticamente significativa al 95% de confianza	Media	Tratar el modelo como piloto, no como reemplazo definitivo, y revalidar la comparación cuando se cuente con más datos
Baja explicabilidad de un modelo de ensamble (Voting de 5 algoritmos) frente a usuarios de negocio sin formación técnica	Media	Complementar cada estimación con el análisis de importancia de variables (SHAP) ya disponible, mostrando al usuario qué factores explican el precio sugerido
Degradación silenciosa del modelo (model drift) si las condiciones del mercado o la	Media	Monitorear el MAPE en producción y establecer un umbral de alerta que dispare un

mezcla de clientes cambian con el tiempo		reentrenamiento si el error supera el observado en validación
--	--	---

Riesgos relacionados con cumplimiento de estándares y gobernanza

Riesgos asociados a la gobernanza del modelo dentro de los procesos comerciales formales de ACCIONA y a su uso responsable:

Riesgo	Severidad	Mitigación propuesta
Ausencia de un proceso formal de aprobación que defina cuándo una cotización puede enviarse al cliente con base únicamente en la sugerencia del modelo	Alta	Definir un protocolo de gobernanza donde toda cotización generada por el modelo requiera revisión y firma de un responsable comercial antes de su envío
Sesgo sistemático hacia los clientes y regiones sobrerrepresentados en el histórico (p. ej. San Luis Potosí, LIMPIEZA y MANTENIMIENTO), perpetuando desigualdades en la precisión del servicio	Media	Reportar y dar seguimiento al error por segmento (como en el análisis de la sección anterior) como parte de la gobernanza periódica del modelo, priorizando la recolección de datos en segmentos subrepresentados
Falta de trazabilidad/auditoría sobre qué versión del modelo generó cada cotización histórica, dificultando responder ante una disputa con un cliente	Media	Registrar en MLflow (o herramienta equivalente) la versión del modelo, los datos de entrada y la fecha de cada cotización generada, como parte del control de versiones ya recomendado

Conclusión ejecutiva

Los resultados obtenidos demuestran que SmartPricing AI es técnicamente viable para apoyar el proceso de estimación de costos de servicios de Facility Management dentro de ACCIONA Facility Services.

El modelo seleccionado (Voting Weighted) alcanzó un MAPE de 35.22% y un R^2 de 0.89, mostrando una capacidad predictiva significativamente superior al modelo base y un desempeño competitivo frente a los modelos individuales evaluados.

Desde una perspectiva de negocio, la solución tiene el potencial de generar beneficios económicos directos estimados en 11,550 EUR anuales, así como una capacidad

operativa equivalente cercana a 69,360 EUR anuales derivada de mejoras en productividad, reducción de retrabajos y estandarización de criterios de costeo.

Aunque existen riesgos relacionados con el tamaño del histórico disponible y la representatividad de algunos segmentos, estos pueden mitigarse mediante una estrategia de implementación gradual basada en pilotos controlados, monitoreo continuo y fortalecimiento de la gobernanza del modelo.

Se recomienda avanzar hacia una fase piloto dentro del área de ofertas de ACCIONA Facility Services, incorporando nuevos datos históricos, mecanismos de monitoreo y una interfaz de usuario que facilite su adopción por parte de los equipos comerciales y operativos.

SmartPricing AI representa una oportunidad para acelerar los procesos comerciales, fortalecer la toma de decisiones basada en datos y contribuir a la transformación digital de ACCIONA Facility Services.

Bibliografía

Babic, B., Cohen, I. G., Evgeniou, T., & Gerke, S. (2021). *When Machine Learning Goes Off the Rails*. Harvard Business Review. <https://hbr.org/2021/01/when-machine-learning-goes-off-the-rails>

Baccarin, F. (2020). *Machine Learning that Pays the Bills: Choosing Models in Business Contexts*. Towards Data Science. <https://towardsdatascience.com/machine-learning-that-pays-the-bills-choosing-models-in-business-contexts-e9003fd434a1>

Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C., & Wirth, R. (2000). *CRISP-DM 1.0: Step-by-step Data Mining Guide*. SPSS.

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., ... & Duchesnay, E. (2011). *Scikit-learn: Machine Learning in Python*. *Journal of Machine Learning Research*, 12, 2825-2830.

Raschka, S., Liu, Y., Mirjalili, V., & Dzhulgakov, D. (2022). *Machine Learning with PyTorch and Scikit-Learn*. Packt Publishing.

Scikit-learn Developers. (2026). *Scikit-learn Documentation*. <https://scikit-learn.org>

XGBoost Developers. (2026). *XGBoost Documentation*. <https://xgboost.readthedocs.io>